

基于肌电信号容错分类的手部动作识别

丁其川^{1,2}, 赵新刚¹, 韩建达¹

(1. 中国科学院沈阳自动化研究所机器人学国家重点实验室, 辽宁 沈阳 110016; 2. 中国科学院大学, 北京 100049)

摘要: 针对肌电交互系统中因电极断开、损坏及数据传输中断等故障造成的数据错误/丢失问题, 提出一种基于高斯混合模型的肌电信号容错分类方法, 通过对肌电信号特征样本中错误/丢失数据边缘化或条件均值归错实现非完整数据样本分类. 应用所提出的方法识别 5 种手部动作, 实验结果表明, 该方法的动作识别精度要高于传统的零归错与均值归错方法. 最后, 融合容错分类机制开发了肌电假手平台, 在线实验验证了提出的方法可以有效提高肌电交互系统的鲁棒性.

关键词: 肌电信号; 数据丢失; 动作分类; 人机交互

中图分类号: TP242

文献标识码: A

文章编号: 1002-0446(2015)-01-0009-08

Recognizing Hand Motions Based on Fault-tolerant Classification with EMG Signals

DING Qichuan^{1,2}, ZHAO Xingang¹, HAN Jianda¹

(1. State Key Laboratory of Robotics, Shenyang Institute of Automation, Chinese Academy of Sciences, Shenyang 110016, China;

2. University of Chinese Academy of Sciences, Beijing 100049, China)

Abstract: In view of the fault/missing data problem caused by disconnected/damaged electrodes and data-transmission interrupting in myoelectric-interface systems, an EMG (electromyography) fault-tolerant classification method based on Gaussian mixture model is proposed, with which an incomplete-data sample can be classified via marginalizing or conditional-mean imputation of the fault/missing data in the EMG feature sample. The proposed method is applied to recognizing five kinds of hand motion. Experimental results show that the proposed method can provide higher motion-recognition accuracy than that by the traditional zero and mean imputation methods. Finally, a myoelectric-hand platform is developed by involving the fault-tolerant classification mechanism, and the online experiments show that the proposed method can effectively improve the robustness of myoelectric-interface systems.

Keywords: EMG; data missing; motion classification; human-robot interface

1 引言 (Introduction)

表面肌电信号 (sEMG) 是肌肉收缩时多个活跃运动单元发出的动作电位序列经由脂肪组织容积滤波后, 在皮肤表面叠加的结果, 它直接反映人体的运动意图^[1]. 以 sEMG 为接口信息构建的人机交互系统已经应用于多种新型服务机器人, 如智能假肢^[2-5]、康复机器人^[6-7]及行为辅助机器人^[8-9]等. 利用 sEMG 实现智能人机交互的核心技术是由 sEMG 准确识别出人体的运动意图^[9].

基于 sEMG 的动作分类问题是当前的一个研究热点^[10-14], 其一般流程包括: 1) 从原始 sEMG 信号中提取特征; 2) 以特征样本为输入构建分类器识别动作模式. 目前, 多数研究都集中在遴选不同的 sEMG 特征与分类器以提高动作识别精度^[3-5,10-15]

方面, 但是当建立的分类模型应用于实际系统时, 必须考虑到模型在非理想情形下的鲁棒性. 肌电系统在线使用时, 表面电极脱落、电极损坏或数据传输中断等故障不可避免, 这些非理想因素必然造成传感器捕获的 sEMG 数据错误/丢失, 如何保证利用完整数据样本离线构建的分类模型, 在在线样本存在错误/丢失数据的情形下, 仍能保持一定的分类精度继续工作, 是研发高鲁棒性肌电交互系统要解决的关键问题. 但是目前并没有基于非完整 sEMG 样本实现动作分类的研究.

本文针对肌电系统应用中存在的输入数据丢失问题, 基于高斯混合模型 (Gaussian mixture model, GMM) 提出一种肌电信号容错分类的方法. 首先利用 sEMG 完整数据样本离线训练一组与动作关

联的 GMM, 当在线样本存在数据丢失时, 通过对丢失部分进行边缘化或条件均值归错, 处理丢失数据, 而后利用贝叶斯决策实现非完整数据样本分类, 该方法可以处理样本中任意丢失数据组合. 随后, 将提出的方法应用于手部动作识别实验, 大量的实验结果以及与传统零归错和均值归错方法的比较, 验证了本文方法的有效性和提高. 最后, 基于构建的容错分类模型, 开发了肌电假手平台. 在线实验表明, 本文方法能有效提高实际肌电系统的鲁棒性.

2 基于 GMM 的 sEMG 容错分类 (sEMG fault-tolerant classification based on GMM)

定义 $\omega_1, \dots, \omega_K$ 为 K 个动作类别, 对应于动作 ω_j 采集的肌电信号完整数据样本集 (所有样本都不包含丢失数据) 为 $X_j = \{\mathbf{x} | \mathbf{x} \in \omega_j\}$, 其中 \mathbf{x} 表示 d 维肌电信号特征向量. 为了描述样本分布, 利用样本集 X_j 离线训练一个对应于 ω_j 的 GMM:

$$p(\mathbf{x} | \omega_j) = \sum_{i=1}^{M_j} \gamma_i^j \mathcal{N}(\mathbf{x} | \mathbf{v}_i^j, \mathbf{C}_i^j), \quad j = 1, \dots, K \quad (1)$$

$$\mathcal{N}(\mathbf{x} | \mathbf{v}_i^j, \mathbf{C}_i^j) = \frac{1}{(2\pi)^{d/2} |\mathbf{C}_i^j|^{1/2}} \exp\left[-\frac{1}{2}(\mathbf{x} - \mathbf{v}_i^j)^T \mathbf{C}_i^{-1}(\mathbf{x} - \mathbf{v}_i^j)\right] \quad (2)$$

其中 $p(\cdot)$ 表示 GMM 概率密度函数 (probability density function, PDF); M_j 是组元个数, 可以通过最小化 Akaike 信息确定^[16]; γ_i^j 是组元系数, 满足 $\gamma_i^j > 0$, $\sum_{i=1}^{M_j} \gamma_i^j = 1$; \mathbf{v}_i^j 是 d 维均值向量, \mathbf{C}_i^j 是 $d \times d$ 维的协方差矩阵, $|\mathbf{C}_i^j|$ 表示 \mathbf{C}_i^j 的行列式; GMM 模型系数 $\{\gamma_i^j, \mathbf{v}_i^j, \mathbf{C}_i^j\}$ 可以利用期望最大化算法计算^[17].

训练后的 GMM 可以结合贝叶斯决策完成新样本的在线分类. 对于在线生成的新样本 $\tilde{\mathbf{x}}$, 首先利用贝叶斯公式计算其属于类 ω_j ($j = 1, 2, \dots, K$) 的后验概率:

$$P(\omega_j | \tilde{\mathbf{x}}) = \frac{P(\omega_j) p(\tilde{\mathbf{x}} | \omega_j)}{\sum_{j=1}^K P(\omega_j) p(\tilde{\mathbf{x}} | \omega_j)} = \lambda P(\omega_j) p(\tilde{\mathbf{x}} | \omega_j) \quad (3)$$

其中 $P(\cdot)$ 定义了概率函数, $P(\omega_j)$ 是训练阶段由样本统计计算的类先验概率, $p(\tilde{\mathbf{x}} | \omega_j)$ 可以由式 (1) 计算, 对于给定的 $\tilde{\mathbf{x}}$, $\lambda = 1 / \sum_{j=1}^K P(\omega_j) p(\tilde{\mathbf{x}} | \omega_j)$ 是一个常数.

然后利用贝叶斯决策^[17] 对 $\tilde{\mathbf{x}}$ 分类, 即 $\tilde{\mathbf{x}}$ 属于类 ω_t , 如果

$$\omega_t = \arg \max_j \{P(\omega_j | \tilde{\mathbf{x}})\} \quad (4)$$

但是实际应用中, 可能会由于部分通道的表面电极脱落、损坏等故障造成在线捕获的样本存在丢失数据. 若定义 $\mathbf{x} = [\mathbf{x}_o^T \quad \mathbf{x}_m^T]^T$ 是包含丢失数据的样本, 其中 \mathbf{x}_o 和 \mathbf{x}_m 分别表示观测到的数据值和丢失数据引起的错误值. 将式 (1) 和式 (2) 中的均值向量 \mathbf{v}_i^j 、协方差矩阵 \mathbf{C}_i^j 以及协方差矩阵的逆 (精度矩阵) 也按照 \mathbf{x} 中观测值和丢失值的比例进行相应分割:

$$\mathbf{v}_i^j = \begin{bmatrix} \mathbf{v}_{i,o}^j \\ \mathbf{v}_{i,m}^j \end{bmatrix}, \quad \mathbf{C}_i^j = \begin{bmatrix} \mathbf{C}_{i,oo}^j & \mathbf{C}_{i,om}^j \\ \mathbf{C}_{i,mo}^j & \mathbf{C}_{i,mm}^j \end{bmatrix}, \quad (5)$$

$$\mathbf{\Lambda}_i^j = \begin{bmatrix} \mathbf{\Lambda}_{i,om}^j & \mathbf{\Lambda}_{i,om}^j \\ \mathbf{\Lambda}_{i,mo}^j & \mathbf{\Lambda}_{i,mm}^j \end{bmatrix}$$

其中 $\mathbf{\Lambda}_i^j = (\mathbf{C}_i^j)^{-1}$.

于是, 可以采用两种途径实现非完整数据样本的容错分类:

1) 边缘化丢失部分

根据式 (1) 计算可观测数据的边缘分布:

$$p(\mathbf{x}_o | \omega_j) = \int p(\mathbf{x} | \omega_j) d\mathbf{x}_m = \sum_{i=1}^{M_j} \gamma_i^j \mathcal{N}(\mathbf{x}_o | \mathbf{v}_{i,o}^j, \mathbf{C}_{i,oo}^j) \quad (6)$$

然后依据 \mathbf{x}_o 信息, 利用贝叶斯决策确定非完整样本 \mathbf{x} 的类 ω_t :

$$\begin{cases} P(\omega_j | \mathbf{x}_o) = \frac{P(\omega_j) p(\mathbf{x}_o | \omega_j)}{\sum_{j=1}^K P(\omega_j) p(\mathbf{x}_o | \omega_j)}, \quad j = 1, \dots, K \\ \omega_t = \arg \max_j \{P(\omega_j | \mathbf{x}_o)\} \end{cases} \quad (7)$$

2) 条件均值归错

给定 \mathbf{x}_o , 由式 (1) 计算 \mathbf{x}_m 的条件分布:

$$p(\mathbf{x}) = p(\mathbf{x}_o, \mathbf{x}_m) = \sum_{j=1}^K P(\omega_j) p(\mathbf{x}_o, \mathbf{x}_m | \omega_j) \quad (8)$$

$$p(\mathbf{x}_m | \mathbf{x}_o) = \sum_{j=1}^K \{P(\omega_j) [\sum_{i=1}^{M_j} \mathcal{N}(\mathbf{x}_m | \mathbf{v}_{i,o|o}^j, (\mathbf{\Lambda}_{i,mm}^j)^{-1})]\} \quad (9)$$

$$\mathbf{v}_{i,m|o}^j = \mathbf{v}_{i,m}^j - (\mathbf{\Lambda}_{i,mm}^j)^{-1} \mathbf{\Lambda}_{i,mo}^j (\mathbf{x}_o - \mathbf{v}_{i,o}^j) \quad (10)$$

于是根据式 (9) 和式 (10) 可以计算给定 \mathbf{x}_o 时, \mathbf{x}_m 的条件均值:

$$\mathbf{x}_{m|o} = \sum_{j=1}^K \left[P(\omega_j) \left(\sum_{i=1}^{M_j} \gamma_i^j \mathbf{v}_{i,m|o}^j \right) \right] \quad (11)$$

然后利用条件均值 $\mathbf{x}_{m|0}$ 替代丢失部分 \mathbf{x}_m , 从而生成一个“完整”样本 $\hat{\mathbf{x}} = [\mathbf{x}_0^T \quad \mathbf{x}_{m|0}^T]^T$, 随后按照完整样本的处理方法对样本 $\hat{\mathbf{x}}$ 分类, 所求结果即是样本 \mathbf{x} 的类别。

3 基于 sEMG 的手部动作识别 (sEMG based hand motion recognition)

下面通过基于 sEMG 的手部动作识别实验评估本文的容错分类方法性能。实验中, 识别 5 种手部动作 (状态): 放松 (relaxing, rlx)、握拳 (grasping hand, grp)、展掌 (opening hand, opn)、捏食指 (pinching the index finger, idx) 和 捏中指 (pinching the middle finger, mid)。定义 5 种手部动作 $\{\text{rlx}, \text{grp}, \text{opn}, \text{idx}, \text{mid}\}$ 为 5 个类 $\{\omega_1, \omega_2, \omega_3, \omega_4, \omega_5\}$ 。

采集与手部运动密切相关的 4 块肌肉的 sEMG: 指伸肌、指屈肌、掌长肌和桡侧腕屈肌, 图 1 展示了各通道 sEMG 电极布置。原始的 sEMG 信号经过放大器 (myoscan) 放大后, 通过 A/D 卡 (PCI1716) 数字化采集, 采样频率 1000 Hz, 随后去除偏置, 并利用截止频率为 500 Hz 的 Butterworth 低通滤波器 和 50 Hz 的陷波器对信号滤波处理。4 名肢体健康测试者 (男性, 年龄 27 ± 3 岁) 参与实验, 每名测试者完成 20 组数据采集试验, 在每组试验中, 测试者以握拳、展掌、捏食指和捏中指的顺序执行手部动作, 每个动作持续约 1.5 s, 每两个动作间以约 2 s 的放松状态间隔, 整个过程重复 2 次, 一组数据采集完成后休息 30 s, 避免肌肉疲劳。每名测试者的前 8 组数据用于训练分类模型 (为每名测试者建立独立的分类模型), 后 12 组数据用于评估模型分类效果。图 2 展示了一组试验数据。




图 1 表面肌电电极布置 (ch- l 表示第 l 通道, $l = 1, 2, 3, 4$)

Fig.1 The placement of the sEMG electrodes (ch- l represents the l -th electrode channel, $l = 1, 2, 3, 4$)

设置 128 ms 的时间窗和 32 ms 的增量窗 (图 3), 用以提取 sEMG 特征。在每个时间窗内, 从每一通道 sEMG 提取 7 种时域特征, 包括均方根 (root mean square) 和 6 阶倒谱系数 (cepstrum coefficient) [15], 然后 4 个通道的所有特征组成一个 28

维 (4×7) 的样本向量 \mathbf{x} , 如下:

$$\mathbf{x} = [\alpha^1 \beta_1^1 \cdots \beta_6^1 \alpha^2 \beta_1^2 \cdots \beta_6^2 \alpha^3 \beta_1^3 \cdots \beta_6^3 \alpha^4 \beta_1^4 \cdots \beta_6^4] \quad (12)$$

其中上标 l ($l = 1, \dots, 4$) 表示电极通道 l 。 α^l 表示由第 l 通道提取的均方根特征, β_i^l ($i = 1, \dots, 6$) 表示由第 l 通道提取的 6 阶倒谱系数特征。




图 2 一组试验的原始表面肌电信号

Fig.2 The raw sEMG signals in an experiment session




图 3 时间窗和增量窗

Fig.3 The time window and increase window

3.1 数据丢失分类结果

以 sEMG 的特征样本为输入, 训练 5 个 GMM (相应于 5 个动作类别), 训练后的 GMM 便可以结合贝叶斯决策实现对新样本的分类。为了定量评估分类效果, 定义分类精度 (classification accuracy, η) 评价指标:

$$\eta = 100\% \times (N_{\text{correct}} / N_{\text{total}}) \quad (13)$$

其中 N_{correct} 表示正确分类样本数, N_{total} 是总样本数。

由于式 (12) 中的特征样本 \mathbf{x} 包含 4 个通道的 sEMG 特征, 因此一个通道的特征占 25% 样本信息。为了评估数据丢失条件下模型的分类效果, 通过手动设置, 将测试集的样本分别设成 1 个通道 sEMG 特征丢失、2 个通道 sEMG 特征丢失和 3 个通道 sEMG 特征丢失 (分别对应 25%、50% 和 75% 的样本信息丢失)。针对某一固定通道数, 考虑所有可能的通道组合, 计算每种通道组合数据丢失条件下

的分类精度, 然后计算对应于该通道数的分类精度均值和标准差。

实验考察 5 种丢失数据处理方法: a) 直接使用错误值替代; b) 零归错 (使用 0 代替丢失数据); c) 均值归错 (使用丢失数据的均值替代, 其中均值可以通过训练数据计算); d) 边缘化丢失数据; e) 条件均值归错。其中 d) 和 e) 是本文提出的容错方法。

图 4 展示了使用一名测试者 (subject-1) 的模型和数据获取的实验结果。其中 WI 表示直接使用错误值, ZI 表示零归错, MI 表示均值归错, Mrg 表示边缘化, CMI 表示条件均值归错。由图 4 可见, 在样本存在丢失数据的情形下, 边缘化方法 (Mrg) 获得的分类精度最高, 比零归错 (ZI) 的分类精度提高约 8%, 而零归错又优于均值归错 (MI) 和条件均值归错 (CMI), 直接使用错误值 (WI) 计算的分类精度最低。




图 4 识别 5 种手部动作时不同方法计算的分类精度均值和标准差 (WI 直接使用错误值, ZI 零归错, MI 均值归错, Mrg 边缘化, CMI 条件均值归错; 25%: 1 个通道, 50%: 2 个通道, 75%: 3 个通道)

Fig.4 The means and standard deviations of classification accuracies calculated by different methods when recognizing five kinds of hand motion (WI: wrong value imputation, ZI: zero imputation, MI: mean imputation, Mrg: marginalization, CMI: conditional mean imputation; 25%: one channel, 50%: two channels, 75%: three channels)

由数据采集阶段的动作规划可知, 在一组数据采集试验中, 手部放松状态 (rlx, 类 ω_1) 占有超过 50% 的数据量 (见图 2), 而与其它动作相比, rlx 关联的 sEMG 特征更接近于 0 (如图 5 所示), 因此在 rlx 状态下, ZI 比 CMI 和 MI 能提供更接近于丢失数据真实值的近似值, 再加上 rlx 的样本数量超过总样本量的 50%, 故造成 ZI 的分类精度高于 CMI 和 MI 方法。

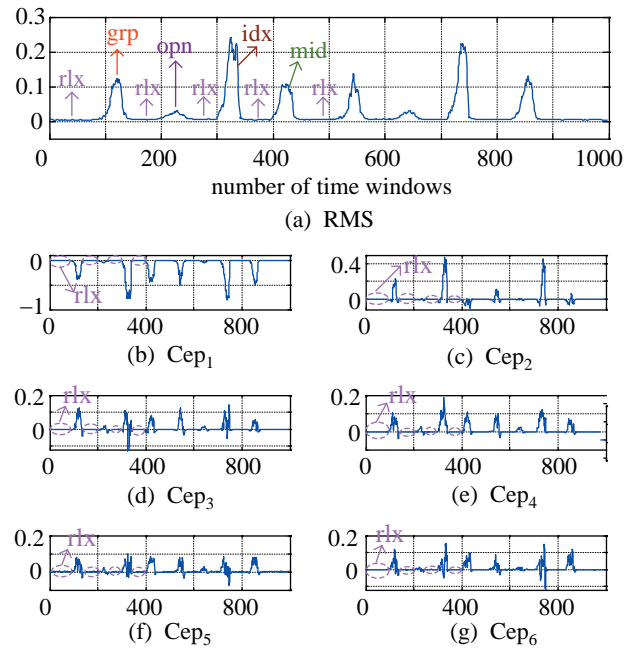


图 5 由图 2 中第 3 通道 sEMG 数据提取的特征, 其中 rlx 占有超过 50% 的数据. (a) 均方根; (b) ~ (g) 倒谱系数

Fig.5 The features extracted from the 3rd channel sEMG-data in Fig.2, in which rlx accounts for more than 50% data. (a) root mean square; (b)~(g) cepstrum coefficients




图 6 识别除 rlx 外 4 种手部动作时不同方法计算的分类精度均值和标准差 (WI 直接使用错误值, ZI 零归错, MI 均值归错, Mrg 边缘化, CMI 条件均值归错; 25%: 1 个通道, 50%: 2 个通道, 75%: 3 个通道)

Fig.6 The means and standard deviations of classification accuracies calculated by different methods when recognizing four kinds of hand motion except rlx (WI: wrong value imputation, ZI: zero imputation, MI: mean imputation, Mrg: marginalization, CMI: conditional mean imputation; 25%: one channel, 50%: two channels, 75%: three channels)

鉴于 rlx (类 ω_1) 的特殊性, 下面仅考虑 4 种手部动作 {grp, opn, idx, mid} 识别问题, 同样利用测试者 subject-1 的模型和数据, 图 6 展示了相应的实验结果。由图 6 可见, Mrg 仍然表现出最好的性

能, 比其它方法的分类精度高 10%~30%。而在排除 rlx 后, CMI 的性能优于 ZI 和 MI。直接使用错误值 (WI) 将极大降低动作类别识别效果。

由图 4 和图 6 的分类精度标准差可知, 不同通道组合数据丢失对分类效果的影响不一致, 这是因为由各个通道提取的样本特征的大小不同, 故某一通道数据丢失, 可能会对一些类的影响很大, 而对另一些类的影响较小。下面具体考察当一个通道数据丢失时, 使用边缘化 (Mrg) 方法分类 4 种手部动作 {grp, opn, idx, mid}, 计算对每一类的分类精度。仍使用测试者 subject-1 的模型和数据, 图 7 展示了相应结果。由图 7 可知, 不同通道影响不同类, 例如通道 1 (ch-1) 数据丢失, 展掌 (opn) 动作的分类精度大大降低 (低于 70%), 而握拳 (grp) 动作的分类精度下降很小 (约 90%); 与之相反, 通道 2 (ch-2) 数据丢失, 则极大降低了 opn 的分类精度, 而对其它动作识别的影响较小。总体而言, 通道 3 (ch-3) 数据对分类影响最大, 通道 4 (ch-4) 数据影响较小。这也反映了肌肉与运动的关联性。

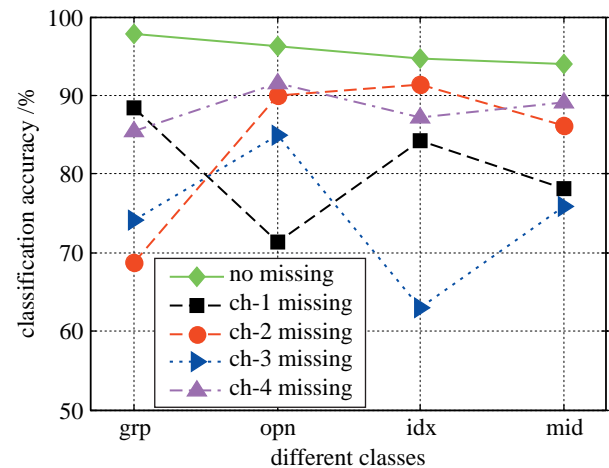


图 7 不同通道数据丢失条件下计算的分类精度
Fig.7 The classification accuracies calculated under the condition of data-missing in different channels

下面分别利用 4 名测试者的模型与数据, 计算不同比例数据丢失条件下的动作分类精度, 然后综合计算总的分类精度均值和标准差。结果列于表 1 和表 2, 其中表 1 对应 5 种手部动作分类, 表 2 对应除放松 (rlx) 状态外其余 4 种手部动作分类。

表 1、2 利用了 4 名测试者所有测试样本集, 由此可见本文的肌电信号容错分类方法对不同的受试者具有一致性。同时, 与其它方法的对比也显示了本文方法的性能提高, 特别当采用边缘化 (Mrg) 方法进行容错分类时, 即便测试样本有两个通道的 sEMG 数据丢失 (50% 的样本信息丢失), 仍可获取

约 70% 的分类精度, 说明本文方法能有效提高分类模型的鲁棒性。参与实验的人员情况如表 1 所示。

表 1 使用 4 名测试者的所有测试数据计算的分类精度均值和标准差 (识别 5 种手部动作)

Tab.1 The means and standard deviations of classification accuracies calculated by using all testing data of four subjects (Recognizing five kinds of hand motion)				
方法 \ 丢失比例	25%	50%	75%	
WI (CA /100%)	0.13±0.12	0.11±0.09	0.11±0.10	
ZI (CA /100%)	0.76±0.09	0.71±0.12	0.68±0.14	
MI (CA /100%)	0.27±0.13	0.22±0.12	0.16±0.13	
Mrg (CA /100%)	0.86±0.08	0.79±0.10	0.72±0.13	
CMI (CA /100%)	0.35±0.11	0.31±0.14	0.19±0.14	

表 2 使用 4 名测试者的所有测试数据计算的分类精度均值和标准差 (识别除 rlx 外 4 种手部动作)

Tab.2 The means and standard deviations of classification accuracies calculated by using all testing data of four subjects (Recognizing four kinds of hand motion except rlx)				
方法 \ 丢失比例	25%	50%	75%	
WI (CA/100%)	0.18±0.10	0.17±0.13	0.15±0.11	
ZI (CA /100%)	0.57±0.17	0.44±0.13	0.28±0.16	
MI (CA /100%)	0.66±0.13	0.51±0.18	0.33±0.12	
Mrg (CA/100%)	0.82±0.10	0.71±0.11	0.55±0.15	
CMI (CA /100%)	0.77±0.11	0.63±0.16	0.41±0.15	

4 肌电假手控制 (Myoelectric hand control)

通过上肢前臂肌肉的 sEMG 解码出手部的运动意图, 然后编码成指令信息控制假手执行相应的动作, 是肌电假手的仿生设计理念, 肌电假手可以帮助手部残疾患者重获手部功能 [2-4]。本节将提出的方法应用于肌电假手平台以提高系统的稳定性和实用性。开发的假手有 4 个电机驱动关节 (拇指、食指、中指各 1 个, 无名指和小指联动), 执行手部动作时, 电机驱动相应关节转动固定角度, 图 8 展示了假手模拟的 5 种手部动作 (状态)。



图 8 假手模仿人的手部动作
Fig.8 The prosthetic hand simulates human hand motion

4.1 肌电假手容错控制

在线应用时, 使用已建立的分类模型 (GMM 结合贝叶斯决策) 对 sEMG 特征样本分类, 识别手部动作类别, 然后将识别结果编码成控制指令控制假手 (图 9(a)). 实验过程中, 如图 9(b) 所示人为断开某几个电极通道, 造成 sEMG 数据丢失. 为了判断在线产生的样本 \mathbf{x} 中是否有某个通道的特征丢失, 定义一个判定准则:

$$|\alpha^l| + \sum_{i=1}^6 |\beta_i^l| > \xi^l, \quad l = 1, \dots, 4 \quad (14)$$

其中上标 l 表示通道 l , α^l, β_i^l ($i = 1, \dots, 6$) 表示由第 l 通道提取 sEMG 特征 (见式 (12)). ξ^l 是预先定义的与第 l 通道关联的阈值.




图 9 肌电假手的在线控制. (a) 肌电假手平台; (b) 断开电极连接造成数据丢失

Fig.9 The online control for the myoelectric hand. (a) The myoelectric-hand platform; (b) Data-missing caused by disconnecting sEMG electrodes

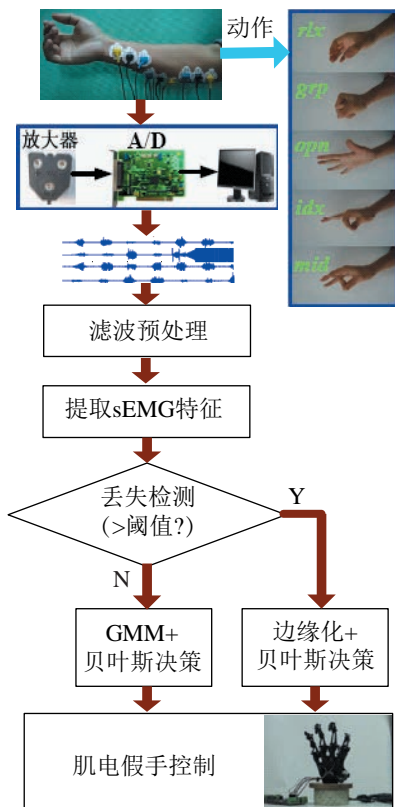
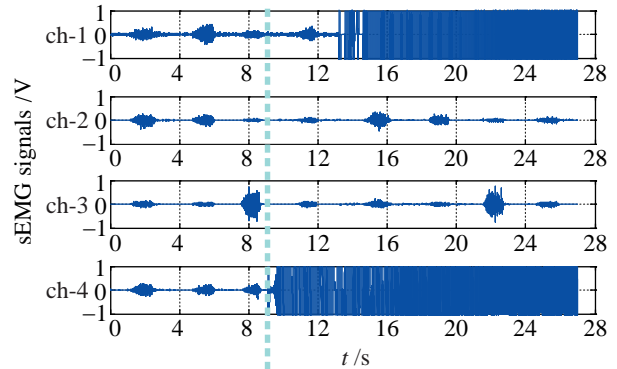



图 10 融合容错分类机制的肌电假手控制
Fig.10 The myoelectric-hand control involving the fault-tolerant classification mechanism


若式 (14) 成立, 则表示相应通道的特征丢失, 那么使用提出的边缘化方法对含有丢失特征的样本分类. 图 10 展示了融合容错分类机制的肌电假手控制框图.



(a) 原始sEMG信号



(b) 有容错机制的分类结果



(c) 无容错机制的分类结果

图 11 一次在线实验结果, 第 9 s 后出现数据丢失. (a) sEMG 信号; (b) 使用容错分类方法获取的结果; (c) 未使用容错分类方法获取的结果. (b) 和 (c) 中红色点和黑色标识符分别表示正确与错误分类

Fig.11 An online experimental result, in which data-missing occurred after 9 s. (a) sEMG signals; (b) The results obtained by using the fault-tolerant classification method; (c) The results obtained without using the fault-tolerant classification method. The red dots and the black asterisks represent the correct and wrong classifications respectively in (b) and (c)

图 11 展示了一组在线实验结果, 实验中, 通道 1 (ch-1) 和通道 4 (ch-4) 的表面电极被人为断开. 图 11(b) 显示了采用容错分类方法识别的手部动作, 可以看到, 在第 9 s 出现 sEMG 数据丢失后, 动作的错误识别数增加, 但是大多数动作模式仍可

以正确识别. 作为比较, 图 11(c) 给出了未使用容错分类方法(直接使用错误值)的动作识别结果, 由图 11(c) 可见, 当样本有特征丢失时, 分类器失效, 几乎不能提供正确的识别结果. 由此可知, 采用提出的策略(图 10)控制肌电假手可以提高系统鲁棒性.

4.2 系统实时性

下面评估肌电假手在线应用的实时性, sEMG 信号采集、分析以及假手的控制程序运行在 Core2 PC 机(主频 2.0GHz)的 Visual Studio 2010 环境下, 测试者(subject-2)共进行 10 组试验, 每组识别 1000 个样本, 识别结果编码成控制指令通过串口发送给假手, 计算从 sEMG 预处理到完成假手控制各个过程的平均耗时, 结果列在表 3 中.

表 3 肌电假手实时性评估
Tab.3 The real-time performance evaluation for the myoelectric hand

过程	平均耗时/ms
sEMG 预处理	1.41
sEMG 特征提取	1.22
丢失检测	0.08
分类	0.70
假手控制	21.44
总计	24.65

由表 3 可知, 进行一次假手控制的平均耗时约为 25 ms, 而设置的用于提取 sEMG 特征的增量窗是 32 ms, 因此可以保证在一个增量窗内完成一次假手控制. 通常情况下, 只要肌电系统的控制周期小于 300 ms, 使用者不会感觉到运行延迟^[4], 因此本文开发的肌电假手平台有推广应用的前景.

5 结论(Conclusion)

本文探索了在肌电信号部分丢失情形下, 如何保证离线构建的分类模型继续有效工作. 基于 GMM 构建了具有容错机制的分类模型, 当在线样本出现数据丢失时, 可以通过边缘化或条件均值归错处理丢失部分. 通过手部动作识别实验验证了所提出方法的有效性, 而与传统零归错和均值归错方法的比较, 更显示了边缘化容错方法性能的提高. 此外, 本文开发了肌电假手平台, 通过融合容错分类机制极大提高了系统的鲁棒性和实用性. 在后续工作中, 我们将识别更多的手部动作, 并考虑在有未知新动作加入的情形下, 如何保证分类模型稳定工作; 同时, 将增加手部残疾患者的实验测试, 完

善肌电假手系统, 使系统能真正为残疾患者带来便利.

参考文献(References)

[1] Pons J L. Wearable robots: Biomechatronic exoskeletons[M]. Hoboken, USA: Wiley, 2008.

[2] 杨大鹏, 赵京东, 李楠, 等. 基于预抓取模式识别的假手肌电控制方法[J]. 机械工程学报, 2012, 48(15): 1-8. Yang D P, Zhao J D, Li N, et al. Recognition of hand grasp pre-shaping patterns applied to prosthetic hand electromyography control[J]. Journal of Mechanical Engineering, 2012, 48(15): 1-8.

[3] 罗志增, 杨广映. 基于触觉和肌电信号的假手模糊控制方法研究[J]. 机器人, 2006, 28(2): 224-228. Luo Z Z, Yang G Y. Prosthetic hand fuzzy control based on touch and myoelectric signal[J]. Robot, 2006, 28(2): 224-228.

[4] Chu J U, Moon I, Lee Y J, et al. A supervised feature-projection-based real-time EMG pattern recognition for multifunction myoelectric hand control[J]. IEEE/ASME Transactions on Mechatronics, 2007, 12(3): 282-290.

[5] Al-Timemy A H, Bugmann G, Escudero J, et al. Classification of finger movements for the dexterous hand prosthesis control with surface electromyography[J]. IEEE Journal of Biomedical and Health Informatics, 2013, 17(3): 608-618.

[6] Cavallaro E E, Rosen J, Perry J C, et al. Real-time myoprocessors for a neural controlled powered exoskeleton arm[J]. IEEE Transactions on Biomedical Engineering, 2006, 53(11): 2387-2396.

[7] Zhang F, Li P F, Hou Z G, et al. sEMG-based continuous estimation of joint angles of human legs by using BP neural network[J]. Neurocomputing, 2012, 78(1): 139-148.

[8] Sankai Y. HAL: Hybrid assistive limb based on cybernics [M]/13th International Symposium on Robotics Research. Berlin, Germany: Springer, 2011: 25-34.

[9] Fleischer C, Hommel G. A human-exoskeleton interface utilizing electromyography[J]. IEEE Transactions on Robotics, 2008, 24(4): 872-882.

[10] Ahsan M R, Ibrahimy M I, Khalifa O O. EMG signal classification for human computer interaction: A review[J]. European Journal of Scientific Research, 2009, 33(3): 480-501.

[11] 张启忠, 席旭刚, 罗志增. 基于非线性特征的表面肌电信号模式识别方法[J]. 电子与信息学报, 2013, 35(9): 2054-2058. Zhang Q Z, Xi X G, Luo Z Z. A pattern recognition method for surface electromyography based on nonlinear features[J]. Journal of Electronics & Information Technology, 2013, 35(9): 2054-2058.

[12] Phinyomark A, Phukpattaranont P, Limsakul C. Feature reduction and selection for EMG signal classification[J]. Expert Systems with Applications, 2012, 39(8): 7420-7431.

[13] 许璇, 谢洪波, 黄虎, 等. 基于文化算法的表面肌电信号特征选择[J]. 计算机应用研究, 2012, 29(3): 910-912. Xu X, Xie H B, Huang H, et al. Feature selection for surface electromyography signal using cultural algorithm[J]. Application Research of Computers, 2012, 29(3): 910-912.

[14] Young A J, Smith L H, Rouse E J, et al. Classification of simultaneous movements using surface EMG pattern recognition[J]. IEEE Transactions on Biomedical Engineering, 2013, 60(5): 1250-1258.

- [15] Tkach D, Huang H, Kuiken T A. Study of stability of time-domain features for electromyographic pattern recognition[J]. Journal of NeuroEngineering and Rehabilitation, 2010, 7: No.21.
- [16] Katmeoka H, Nishimoto T, Sagayama S. Separation of harmonic structures based on tied Gaussian mixture model and information criterion for concurrent sounds[C]//IEEE International Conference on Acoustics, Speech, and Signal Processing, Piscataway, USA: IEEE, 2004: 297-300.
- [17] Bishop C M. Pattern recognition and machine learning[M]. New York, USA: Springer, 2006.

(上接第 8 页)

- [12] White G C, Xu Y S. An active vertical-direction gravity compensation system[J]. IEEE Transactions on Instrumentation and Measurement, 1994, 43(46): 786-792.
- [13] NASA. Active response gravity offload system[EB/OL]. [2012-08-30]. http://www.nasa.gov/centers/johnson/engineering/integrated_environments/active_response_gravity/.
- [14] 姚燕生. 3 维重力补偿方法与空间浮游目标模拟实验装置研究 [D]. 合肥: 中国科学技术大学, 2006.
- Yao Y S. Research on 3D gravity compensation and equipment of space floating objective simulation[D]. Hefei: University of Science and Technology of China, 2006.
- [15] 姚燕生, 梅涛, Liu Ming, 等. 悬挂式重力补偿系统精密跟踪方法 [J]. 哈尔滨工业大学学报, 2009, 41(11): 205-208.
- Yao Y S, Mei T, Liu M, et al. Precision tracking method in suspension system for gravity compensation[J]. Journal of Harbin Institute of Technology, 2009, 41(11): 205-208.
- [16] 林旭梅. 基于小脑模型的智能控制方法及其在重力补偿系统中的应用 [D]. 合肥: 中国科学技术大学, 2006.
- Lin X M. Intelligent control method based on CMAC theory and its application on microgravity compensation system[D]. Hefei: University of Science and Technology of China, 2006.
- [17] 孟瑶. 巡视器地面六分之一重力模拟中的控制研究 [D]. 哈尔滨: 哈尔滨工业大学, 2010.

作者简介:

丁其川 (1984-), 男, 博士. 研究领域: 生物信号处理, 机器学习.

赵新刚 (1978-), 男, 博士, 副研究员. 研究领域: 医疗服务机器人, 无人机自主控制.

韩建达 (1968-), 男, 博士, 研究员, 博士生导师. 研究领域: 非线性系统理论, 移动机器人自主控制, 医疗机器人.

Meng Y. The study of control system design on lunar gravity simulator in an earth gravity environment[D]. Harbin: Harbin Institute of Technology, 2010.

[18] 刘延柱. 高等动力学 [M]. 北京: 高等教育出版社, 2010: 4-30.

Liu Y Z. Advanced dynamics[M]. Beijing: Higher Education Press, 2010: 4-30.

[19] 梅晓榕. 自动控制原理 [M]. 北京: 科学出版社, 2007: 112-176.

Mei X R. Autocontrol theory[M]. Beijing: Science Press, 2007: 112-176.

[20] 王广雄, 何朕. 控制系统设计 [M]. 北京: 清华大学出版社, 2008: 36-175.

Wang G X, He Z. Control system design[M]. Beijing: Tsinghua University Press, 2008: 36-175.

作者简介:

邹胜宇 (1988-), 男, 硕士生, 助理工程师. 研究领域: 宇航空间机构及控制.

刘 振 (1983-), 男, 博士, 讲师. 研究领域: 空间机构及系统的重力补偿.

高海波 (1970-), 男, 博士, 教授. 研究领域: 特种机器人技术、宇航空间机构及控制.